Pipeline ETL con Capa de Cuarentena en un Data Lake Simulado

Ethan Jeriel Lopez Patiño

Escuela Politécnica Nacional, Quito, Ecuador
correo@epn.edu.ec

Resumen Se intervino un pipeline ETL en Google Colab sobre 5,050,000 transacciones sintéticas con ruido (nulos, duplicados y outliers). Se implementó una capa de cuarentena para valores atípicos, un descarte inteligente de transacciones canceladas sin monto y la estandarización estadística del monto, organizando los datos en las capas RAW, QUARANTINE y CURATED.

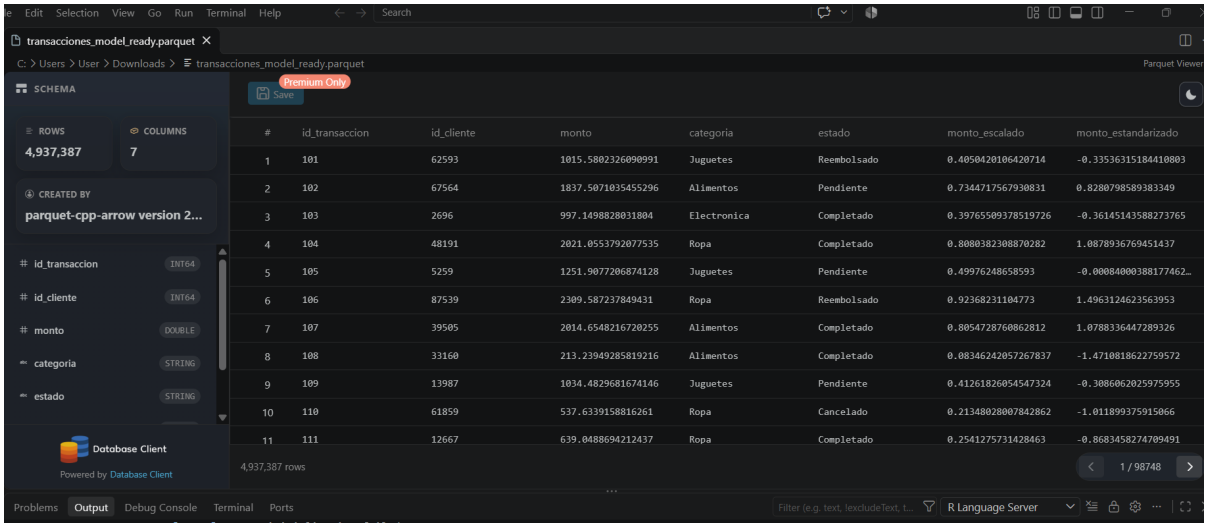
Keywords: ETL · Data Lake · Calidad de datos · Parquet

1. Introducción

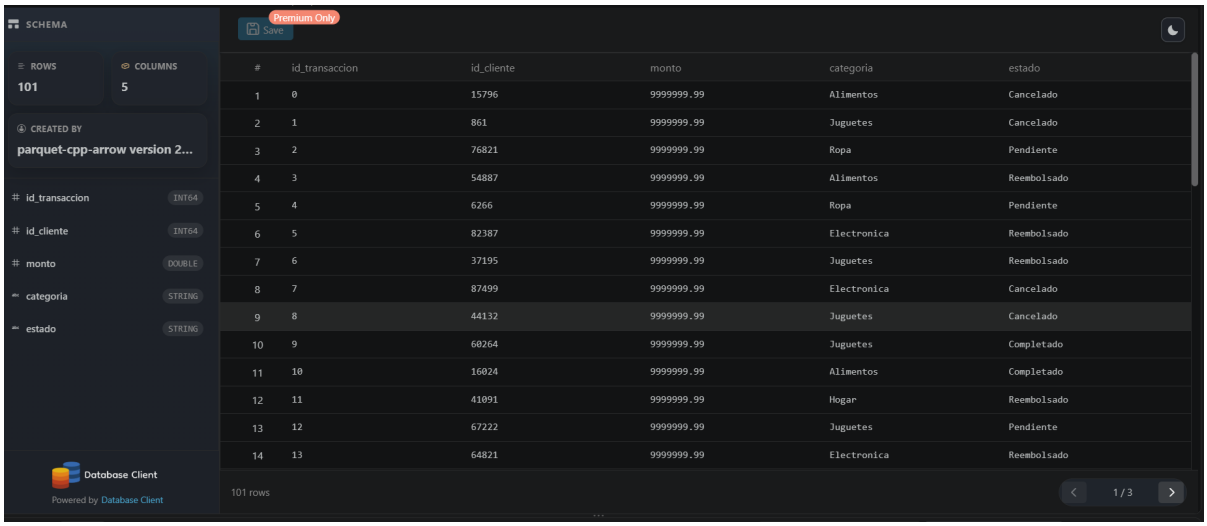
En los entornos de Big Data, los datos suelen llegar con ruido: valores nulos, registros duplicados y valores atípicos que comprometen la calidad de los análisis posteriores. Un Data Lake bien diseñado no solo almacena la información, sino que la organiza en capas que garantizan trazabilidad y gobernanza. Este trabajo interviene un pipeline ETL en Google Colab que procesa 5,050,000 transacciones sintéticas con ruido inyectado, organizadas en las capas RAW, QUARANTINE y CURATED. Se resolvieron dos retos de ingeniería: (1) aislar los valores atípicos detectados mediante la regla IQR en una capa de cuarentena en formato Parquet, y (2) aplicar un descarte inteligente de transacciones canceladas sin monto, manteniendo la imputación por mediana por categoría en los demás estados.`monto` mediante Z-score.

2. Capturas Data Lakes

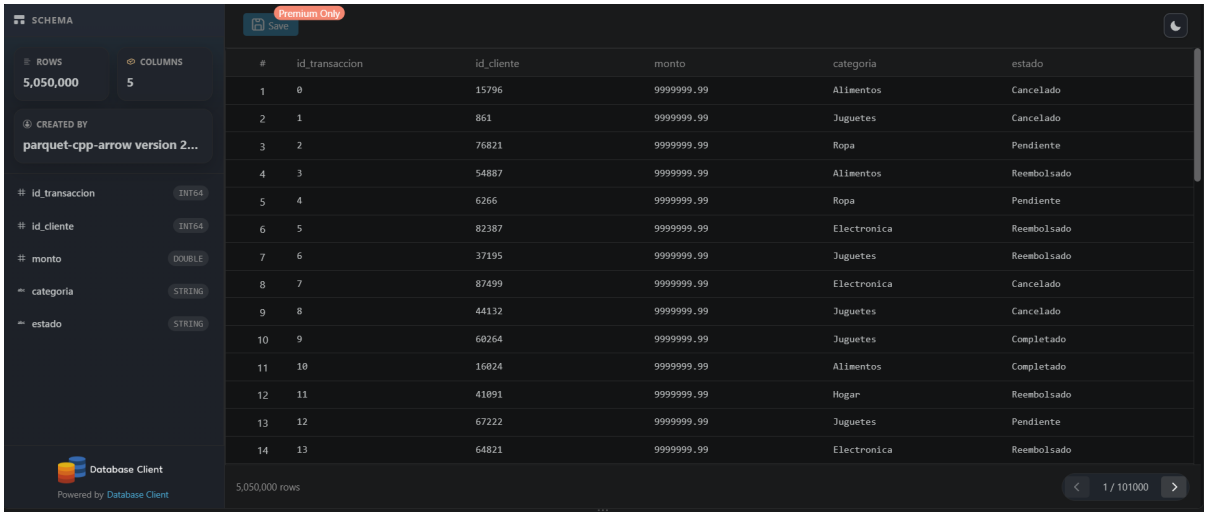
2.1. Modelo de transiciones



2.2. Salida transacciones



2.3. Ingesta transacciones



#	id_transaccion	id_cliente	monto	categoria	estado
1	0	15796	9999999.99	Alimentos	Cancelado
2	1	861	9999999.99	Juguetes	Cancelado
3	2	76821	9999999.99	Ropa	Pendiente
4	3	54887	9999999.99	Alimentos	Reembolsado
5	4	6266	9999999.99	Ropa	Pendiente
6	5	82387	9999999.99	Electronica	Reembolsado
7	6	37195	9999999.99	Juguetes	Reembolsado
8	7	87499	9999999.99	Electronica	Cancelado
9	8	44132	9999999.99	Juguetes	Cancelado
10	9	60264	9999999.99	Juguetes	Completado
11	10	16024	9999999.99	Alimentos	Completado
12	11	41091	9999999.99	Hogar	Reembolsado
13	12	67222	9999999.99	Juguetes	Pendiente
14	13	64821	9999999.99	Electronica	Reembolsado

2.4. Reto 1:

```python
# 3. Tratamiento de Outliers (Regla IQR)
Q1 = df_limpio['monto'].quantile(0.25)
Q3 = df_limpio['monto'].quantile(0.75)
IQR = Q3 - Q1
limite_superior = Q3 + 1.5 * IQR

# RETO 1: Capa de Cuarentena
mascara_outliers = df_limpio['monto'] > limite_superior
df_cuarentena = df_limpio.loc[mascara_outliers].copy()
df_limpio = df_limpio.loc[~mascara_outliers].copy()

os.makedirs('./datalake/quarantine', exist_ok=True)
ruta_cuarentena = './datalake/quarantine/outliers_transacciones.parquet'
df_cuarentena.to_parquet(ruta_cuarentena, engine='pyarrow', index=False)
print(f"Outliers enviados a cuarentena: {len(df_cuarentena):,}")
print(f"Archivo guardado en: {ruta_cuarentena}")
print(f"Registros que continúan hacia Curated: {len(df_limpio):,}")

# 4. Normalización Min-Max (Escala de 0 a 1)
```

2.5. Reto 2:

```python
# 2. Imputación robusta de Nulos (Mediana por categoría)
# RETO 2: Descarte inteligente
condicion_cancelado_nulo = (
    (df_limpio['estado'] == 'Cancelado') &
    (df_limpio['monto'].isnull())
)
filas_descartadas = condicion_cancelado_nulo.sum()
df_limpio = df_limpio.loc[~condicion_cancelado_nulo].copy()
print(f"Transacciones Canceladas eliminadas por monto nulo: {filas_descartadas:,

# Imputación con mediana por categoría para los demás estados
medianas = df_limpio.groupby('categoria')['monto'].transform('median')
df_limpio['monto'] = df_limpio['monto'].fillna(medianas)
print(f"Nulos restantes en monto: {df_limpio['monto'].isnull().sum()}")

# 3. Tratamiento de Outliers (Regla IQR)
Q1 = df_limpio['monto'].quantile(0.25)
Q3 = df_limpio['monto'].quantile(0.75)
IQR = Q3 - Q1
limite_superior = Q3 + 1.5 * IQR
```

3. Justificación arquitectónica

El Data Lake se dividió en tres capas. **RAW** conserva la ingesta original e inmutable, lo que garantiza trazabilidad y permite reprocesar los datos si es necesario. **CURATED** contiene solo registros validados y listos para modelado. **QUARANTINE** aísla los registros sospechosos sin destruirlos.

Reto 1. Eliminar los outliers detectados por IQR es irreversible, y un monto extremo puede ser un error de origen o una señal de fraude. Por eso los 101 registros se guardaron en `./datalake/quarantine`: la capa CURATED queda protegida de valores como 9,999,999.99 y el negocio conserva la posibilidad de auditarlos.

Reto 2. Una imputación generalizada introduce sesgo. Una transacción `Cancelado` sin monto no aporta valor predictivo, por lo que se eliminaron 62,513 filas. En los demás estados el monto sí es relevante, así que se imputó con la mediana por categoría, robusta ante valores extremos.

Todas las capas se almacenaron en Parquet por su formato columnar y su compresión, que reducen espacio y aceleran las lecturas.

4. Github

https://github.com/Jeriel2/s7.git